

PIPELINE COMPLETO DE PLN PARA CLASSIFICAÇÃO E ANÁLISE DE NOTÍCIAS

Disciplina: Processamento de Linguagem Natural (PLN)

Aluno: Rennan da Hora Araujo

Título do Projeto: Construção de Pipeline End-to-End para Classificação Semântica e Extração de Grafos de Conhecimento do Corpus BBC News

Github: https://github.com/rennyzito/PLN_PD

Streamlit: <https://pln-pd-infnet.streamlit.app/>

1. Descrição e Justificativa do Corpus

1.1 Descrição do Corpus Escolhido

O projeto utiliza o corpus público BBC News Classification, obtido diretamente do repositório público de dados textuais. O banco de dados é composto por 2.225 documentos textuais (notícias reais da BBC), distribuídos em 5 classes/categorias distintas: business, entertainment, politics, sport e tech.

1.2 Justificativa de Escolha e Adequação aos Critérios Mínimos

O corpus cumpre com folga todas as exigências do projeto:

- **Volume Suficiente:** Possui 2.225 documentos (mínimo exigido: 1.000).
- **Densidade Textual:** Os artigos são longos, contendo uma média superior a 200 palavras por documento.
- **Balanceamento de Classes:** Apresenta 5 categorias comparáveis com distribuição equilibrada de documentos.
- **Presença de Entidades:** O texto em inglês é rico em entidades nomeadas (Pessoas, Organizações e Locais), essenciais para a extração de informação.
- **Reprodutibilidade e Citação:** Fonte pública e citável, permitindo a execução rápida em computadores pessoais comuns sem a necessidade de GPU dedicada.

2. Caracterização Inicial e Pré-processamento Textual

2.1 Descrição do Pipeline de Pré-processamento

O pipeline foi desenvolvido utilizando as bibliotecas NLTK e spaCy, composto pelas seguintes etapas sequenciais:

1. **Conversão para Minúsculas (Lowercasing):** Padronização do texto.
2. **Remoção de Pontuação:** Eliminação de ruídos ortográficos através da tabela de tradução `string.punctuation`.
3. **Tokenização por Palavra:** Divisão da string bruta em tokens utilizando o modelo estatístico do spaCy.
4. **Remoção de Stopwords:** Filtragem das palavras gramaticais mais comuns da língua inglesa (`nltk.corpus.stopwords`) adicionando stopwords customizadas identificadas no domínio jornalístico: "said", "would" e "also".
5. **POS Tagging (Part-of-Speech):** Mapeamento morfológico de cada token (Verbos, Substantivos, Adjetivos).
6. **Redução Radical:** Aplicação de lematização.

2.2 Comparação Técnica: Stemming vs. Lematização

- **Stemming (Algoritmo de Porter):** Remove os afixos e sufixos de maneira puramente heurística e estrutural. Por exemplo, a palavra "applications" é reduzida para "applic", que não é uma palavra dicionarizada.
- **Lematização (spaCy):** Utiliza uma análise morfológica completa baseada no contexto gramatical da palavra (via POS Tagging). A palavra "applications" é corretamente reduzida ao seu lema nominal "application", e o verbo "are" retorna ao seu infinitivo "be".
- **Decisão:** Optou-se por seguir o pipeline utilizando os dados lematizados. Embora o stemming seja computacionalmente mais rápido, a lematização preserva a integridade semântica dos termos, o que mitiga problemas de over-stemming e garante maior precisão para o motor de busca por similaridade e para a modelagem posterior.

3. Representação Vetorial e Mecanismo de Busca Textual

3.1 Abordagem de Vetorização Utilizada

Transformamos os textos limpos e lematizados em matrizes numéricas utilizando o modelo TF-IDF (Term Frequency - Inverse Document Frequency) através da classe `TfidfVectorizer` do `scikit-learn`.

- **Justificativa:** Diferente do modelo simples de contagem (Bag-of-Words), o TF-IDF penaliza palavras muito frequentes em todo o corpus jornalístico e valoriza termos raros e específicos de cada documento, gerando maior poder de discriminação matemática para os algoritmos de classificação. O vocabulário foi limitado a `max_features=3000` para otimizar o desempenho computacional sem perda de acurácia.

3.2 Mecanismo de Busca por Similaridade de Cosseno

Foi implementado um algoritmo que recebe uma consulta em formato de texto, converte essa consulta para o mesmo espaço vetorial do TF-IDF e calcula a Similaridade de Cosseno contra todos os 2.225 documentos do corpus. O sistema retorna o ranking dos 3 documentos com maior score angular.

3.3 Evidências e Validação do Motor de Busca

Foram conduzidos os 3 testes obrigatórios determinados pelo projeto:

1. **Consulta 1:** "computer software" - Retornou de forma coerente artigos classificados estritamente como tech, apresentando scores de similaridade médios de 0.54.
2. **Consulta 2:** "election vote" - Mapeou com precisão documentos pertencentes à classe politics, focados em dinâmicas de votações governamentais.
3. **Consulta 3:** "football player" - Retornou perfeitamente notícias sobre campeonatos e atletas da classe sport com score máximo de aderência.

4. Modelagem e Classificação Supervisionada

4.1 Técnicas Aplicadas e Divisão dos Dados

Como o corpus original possui rótulos explícitos de categorias na coluna category, aplicou-se a abordagem de Classificação Supervisionada. Os dados foram particionados na proporção clássica de 80% para treinamento e 20% para teste, aplicando estratificação (stratify) para manter o balanceamento proporcional das 5 classes em ambos os conjuntos. Foram treinados e comparados dois modelos:

1. **Naive Bayes (MultinomialNB):** Modelo probabilístico baseado no Teorema de Bayes.
2. **Regressão Logística (LogisticRegression):** Algoritmo linear robusto com regularização.

4.2 Métricas de Avaliação Comparativa

Modelo Algorítmico	Precision Global	Recall Global	F1-Score Global	Acurácia (Accuracy)
Naive Bayes	0.99	0.99	0.99	99%

Regressão Logística	0.98	0.98	0.98	98%
----------------------------	-------------	-------------	-------------	------------

4.3 Análise da Matriz de Confusão

O modelo Naive Bayes obteve um desempenho ligeiramente superior, alcançando 99% de acurácia geral. A análise detalhada da Matriz de Confusão revelou um comportamento analítico excelente:

- A categoria sport obteve acerto absoluto (100% de recall), dado o vocabulário restrito e exclusivo do segmento (termos como match, stadium, coach).
- Ocorreu uma sutil interseção (confusão de apenas 2 documentos) entre as classes business e politics. No domínio jornalístico real, essa sobreposição é perfeitamente justificável, visto que decisões econômicas, orçamentárias e fiscais estão diretamente atreladas a eventos e votações do corpo político do governo.

5. Extração de Informação e Grafo de Conhecimento

5.1 Extração de Entidades Nomeadas (NER) e Relações

Utilizando o pipeline estatístico de Reconhecimento de Entidades Nomeadas (NER) do spaCy (en_core_web_sm), filtramos as entidades mapeadas como PERSON (Pessoas) e ORG (Organizações) presentes nas notícias de política. Uma aresta (conexão) foi estabelecida no grafo sempre que uma pessoa e uma organização coexistiam dentro do mesmo texto jornalístico, resultando em uma rede complexa composta por 145 nós únicos.

5.2 Análise de Centralidade de Grau (Degree Centrality) e Interpretação

Aplicou-se a métrica de Centralidade de Grau via NetworkX para quantificar a relevância dos atores:

1. **Tony Blair (Centralidade: 0.0972):** Identificado como o principal nó conector da rede. Sendo o Primeiro-Ministro britânico no período do corpus, ele opera como o principal canal de tráfego semântico, ligando diferentes partidos e secretarias.
2. **BBC (Centralidade: 0.1111):** Sendo a corporação de mídia pública que assina os textos, atua como o eixo institucional cruzado nas menções.
3. **Australia's Liberal Party (Centralidade: 0.1250):** O aparecimento em formato de estrela ("hub centralizado") decorre de artigos específicos de cobertura internacional que listavam múltiplos parlamentares vinculados a uma única legenda.

6. Comunicação: Síntese Executiva (Stakeholder Não Técnico)

6.1 Resumo dos Resultados de Negócio

A implementação deste pipeline completo de Processamento de Linguagem Natural prova que dados de texto livre e desestruturado podem ser convertidos em ativos estratégicos e automatizados com alto grau de confiança:

- **Triagem Automatizada Eficiente:** A empresa passa a contar com um classificador inteligente capaz de catalogar e direcionar textos de forma automática com 99% de precisão, reduzindo drasticamente custos e horas de esforço humano com leitura manual.
- **Recuperação de Informação Inteligente:** O mecanismo de busca por similaridade permite que analistas localizem documentos não apenas por palavras-chave rígidas, mas por afinidade de contexto semântico global.
- **Inteligência de Rede (Market Intelligence):** Através dos grafos, mapeamos visualmente quem são os influenciadores e as corporações mais citadas do ecossistema, identificando polos de interesse e conexões de mercado de forma totalmente automatizada.

7. Limitações, Melhorias e Reprodutibilidade

7.1 Limitações do Pipeline Atual

1. O pipeline atual é dependente de modelos estatísticos pré-treinados de menor escala (en_core_web_sm), o que pode gerar pequenas falhas ou ruídos na classificação de entidades nomeadas muito raras (NER).
2. A matriz TF-IDF captura frequências estatísticas de palavras, mas desconsidera a ordem sequencial profunda e o contexto de polissemia que modelos mais modernos conseguem reter.

7.2 Possíveis Melhorias

1. Substituir a representação vetorial do TF-IDF por modelos de embeddings densos contextuais (como instâncias do BERT ou arquiteturas de Transformers através da biblioteca Hugging Face).
2. Implementar técnicas de correção ortográfica com Distância de Levenshtein antes da etapa de tokenização para lidar com possíveis erros tipográficos ou de digitação nos textos.

7.3 Instruções para Reprodução Absoluta do Projeto

1. Certifique-se de ter instalado o Python 3.8+ e as dependências listadas no topo do arquivo do aplicativo (pandas, nltk, spacy, scikit-learn, networkx, matplotlib, streamlit).
2. Execute os comandos de download dos dicionários: `python -m spacy download en_core_web_sm` e as dependências de stopwords do NLTK.
3. Garanta conexão ativa com a internet para que o pandas possa consumir o CSV do repositório remoto público no momento da execução inicial.